การวิเคราะห์ปัจจัยเพื่อการจำแนกระดับความรุนแรงของอุบัติเหตุทางถนนด้วยเทคนิคการเรียนรู้ของเครื่อง

จินตนา ณ วิเชียร*[1] และ ผศ.ดร. อนันตพัฒน์ อนันตชัย[2]

คณะเทคโนโลยีสารสนเทศ สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

เลขที่ 1 ซอยฉลองกรุง 1 แขวงลาดกระบัง เขตลาดกระบัง กรุงเทพฯ 10520

บทคัดย่อ

การศึกษานี้มุ่งพัฒนาแบบจำลองสำหรับจำแนกระดับความรุนแรงของอุบัติเหตุทางถนนออกเป็น 3 ระดับ ได้แก่ Severe (KA), Minor (BC) และ No Injury (O) โดยใช้ชุดข้อมูล Traffic Accidents จาก Kaggle จำนวน 209,306 แถว 18 ตัวแปร หลังทำความสะอาดข้อมูลได้ 171,519 แถว 17 ตัวแปร จากนั้นแบ่งเป็นชุดฝึก 80% และชุดทดสอบ 20% แปลงตัวแปรเชิงหมวดหมู่ด้วย One-Hot Encoding ปรับสมดุลคลาสด้วย Undersampling และคัดเลือกตัวแปรด้วยการทดสอบไคสแควร์ที่ระดับ p-value < 0.05 จากนั้นสร้างแบบจำลองด้วย Random Forest, LightGBM และ CatBoost พร้อมรวมผลด้วย Soft Voting Ensemble โดยปรับค่าความเหมาะสมด้วย Grid Search Cross-Validation และประเมินด้วย Accuracy, Precision, Recall และ F1-Score ผลการทดสอบพบว่า Random Forest ให้ค่า F1-Macro สูงสุดที่ 0.5433 ขณะที่ CatBoost ตรวจจับอุบัติเหตุรุนแรงได้ดีที่สุดด้วยค่า Recall 0.5269 อย่างไรก็ดี ยังมีข้อท้าทายในการพัฒนาแบบจำลองให้มีประสิทธิภาพมากขึ้นในการจำแนกคลาส KA ซึ่งสะท้อนให้เห็นถึงความไม่สมดุลของคลาสยังคงเป็นปัญหาหลักที่ต้องพัฒนาแก้ไขต่อไป

คำสำคัญ: การจำแนกประเภท, การเรียนรู้ของเครื่อง, อุบัติเหตุทางถนน

---

* Author's Email: 67076012@it.kmitl.ac.th

[1] นักศึกษาปริญญาโท สาขาวิชาปัญญาประดิษฐ์เพื่อการวิเคราะห์เชิงธุรกิจ คณะเทคโนโลยีสารสนเทศ สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

[2] ผู้ช่วยศาสตราจารย์ คณะเทคโนโลยีสารสนเทศ สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

1.บทนำ

1.1 ที่มาและความสำคัญ

เหตุรถชนบนท้องถนนสามารถคร่าชีวิตผู้คนปีละหลายล้านราย ข้อมูลขององค์การอนามัยโลก (WHO, 2018) ระบุว่าตัวเลขอยู่ราว 1.35 ล้านคนต่อปี ซึ่งนับว่าเป็นปัญหาเกี่ยวกับสาธารณสุขที่ร้ายแรงในระดับสากล ในสังคมของไทยผลเสียไม่ได้มีแค่ความสูญเสียทางร่างกายหรือทรัพย์สิน แต่ยังกระทบต่อระบบเศรษฐกิจโดยตรง เพราะผู้ที่เสียชีวิตส่วนใหญ่นั้นอยู่ในช่วงวัยแรงงาน ดังนั้นการทำความเข้าใจว่าอะไรเป็นปัจจัยที่บ่งชี้ระดับความรุนแรงของอุบัติเหตุ จึงมีคุณค่าอย่างยิ่ง เพราะข้อมูลเหล่านี้จะช่วยทำให้ผู้ที่เกี่ยวข้องกับการกำหนดนโยบายสามารถวางแผนเพื่อป้องกันได้ตรงจุดมากขึ้น [1]

ในปัจจุบันเครื่องมือด้าน AI และ Machine Learning ทำให้การวิเคราะห์ข้อมูลอุบัติเหตุทำได้ละเอียดกว่าแต่ก่อนมาก ตัวแปรหลายมิติ ไม่ว่าจะเป็นสภาพอากาศ ช่วงเวลา ลักษณะถนน หรือระดับทัศนวิสัย ล้วนสามารถนำมาวิเคราะห์ร่วมกันได้ในคราวเดียว

การศึกษานี้จึงประยุกต์ใช้เทคนิค ML มาสร้างตัวแบบที่บ่งบอกได้ว่าอุบัติเหตุแต่ละกรณีอยู่ในระดับของความรุนแรงเพียงใด โดยใช้ชุดข้อมูล Traffic Accidents ของ Oktay Ördekçi ที่เผยแพร่บน Kaggle [2] เพื่อสาธิตว่าผลจำแนกจากการวิเคราะห์นี้สามารถนำไปหนุนการตัดสินใจแบบนโยบายได้อย่างไร

1.2 วัตถุประสงค์ของการศึกษา

1.2.1 เพื่อศึกษาและวิเคราะห์ปัจจัยที่เชื่อมโยงกับระดับความรุนแรงของอุบัติเหตุทางถนน

1.2.2 เพื่อพัฒนาแบบจำลอง Machine Learning สำหรับจำแนกระดับความรุนแรงของอุบัติเหตุ

1.3 ประโยชน์ที่คาดว่าจะได้รับ

1.3.1 ได้องค์ประกอบความรู้จากการทดลองแบบจำลองที่เกี่ยวข้องกันระหว่างความสัมพันธ์ของปัจจัยต่าง ๆ กับระดับความรุนแรงของอุบัติเหตุทางถนน

1.3.2 ได้แบบจำลองที่มีผลลัพธ์ที่แม่นยำในระดับน่าเชื่อถือสำหรับคาดการณ์ระดับความรุนแรงของอุบัติเหตุ เพื่อเป็นตัวช่วยตัดสินใจของแต่ละหน่วยงานที่เกี่ยวกับงานด้านความปลอดภัยทางถนน

2. ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 ไคสแควร์ (Chi-Square Test)

ไคสแควร์เป็นเครื่องมือสำหรับงานทางสถิติที่ช่วยบอกว่าตัวแปรเชิงหมวดหมู่สองตัวมีความเกี่ยวพันกันจริงหรือไม่ แนวคิดหลักคือการนำจำนวนที่นับได้จริงไปเทียบกับจำนวนที่ควรจะเป็นถ้าตัวแปรทั้งคู่ไม่เกี่ยวข้องกันเลย ถ้าผลต่างระหว่างสองค่านี้สูงเกินเกณฑ์ที่ตั้งไว้ ก็พอจะสรุปได้ว่าตัวแปรมีความสัมพันธ์กัน [3] มีการเลือกใช้ไคสแควร์เป็นตัวกรอง โดยมีการเก็บเฉพาะตัวแปรที่จะให้ p-value ต่ำกว่า 0.05 เอาไว้ เพื่อตัดตัวแปรที่ไม่ช่วยเพิ่มประสิทธิภาพออกก่อนที่จะเริ่มต้นสร้างแบบจำลอง

2.2 Encoding

อัลกอริทึม ML ส่วนใหญ่ทำงานกับตัวเลขเท่านั้น ดังนั้นข้อมูลที่เป็นข้อความหรือหมวดหมู่จึงต้องถูกดัดแปลงให้เป็นตัวเลขเสียก่อน งานนี้ใช้วิธี One-Hot Encoding ซึ่งจะกระจายแต่ละหมวดหมู่ออกเป็นคอลัมน์ใหม่ แล้วใส่ค่า 0 กับ 1 เพื่อบอกว่าข้อมูลแถวนั้นอยู่ในหมวดหมู่ไหน ข้อดีของวิธีนี้คือแบบจำลองจะไม่เข้าใจผิดว่าหมวดหมู่ต่าง ๆ มีลำดับสูงต่ำ ซึ่งเป็นเทคนิคที่เข้ากันดีกับวิธีการเชิงคำนวณที่ใช้ตระกูลต้นไม้ตัดสินใจ [4]

2.3 Random Forest (RF)

Random Forest ถูกออกแบบมาบนแนวคิดที่ว่าการรวมผลจากแบบจำลองหลายตัวย่อมให้ความแม่นยำสูงกว่าการใช้แบบจำลองเดี่ยว วิธีการเชิงคำนวณนี้สร้างต้นไม้ตัดสินใจจำนวนมากโดยแต่ละต้นเรียนรู้จากชุดข้อมูลย่อยที่สุ่มขึ้นมาแบบมีการทดแทน และในแต่ละจุดแยกสาขาจะสุ่มเลือกเพียงบางส่วนของตัวแปรมาพิจารณา ความหลากหลายที่เกิดจากกลไกนี้ทำให้ต้นไม้แต่ละต้นมีลักษณะแตกต่างกัน และเมื่อนำผลการทำนายมารวมกันด้วยคะแนนเสียงข้างมาก ความผิดพลาดของต้นไม้แต่ละต้นจะหักล้างกันจนได้ผลลัพธ์ที่เสถียรและแม่นยำกว่า [5]

Wang และคณะ (2024) ได้ประยุกต์ใช้ Random Forest ในการทำนายระดับความรุนแรงของอุบัติเหตุจราจร ผลการศึกษาพบว่าวิธีการเชิงคำนวณนี้แสดงให้เห็นถึงศักยภาพในการจัดการกับข้อมูลที่มีความสัมพันธ์ซับซ้อนได้ค่อนข้างดี โดยเฉพาะปัจจัยด้านสภาพแวดล้อมและโครงสร้างที่ส่งผลต่อการพยากรณ์อย่างเห็นได้ชัด [6]

2.4 LightGBM (Light Gradient Boosting Machine)

LightGBM เป็นวิธีการเชิงคำนวณ Gradient Boosting ที่ Microsoft พัฒนาขึ้นโดยมุ่งแก้ปัญหาด้านความเร็วและการขยายขนาดสำหรับข้อมูลขนาดใหญ่เป็นหลัก จุดที่ทำให้แตกต่างจาก XGBoost อย่างเด่นชัดคือกลยุทธ์การขยายต้นไม้แบบ Leaf-wise ที่ในแต่ละรอบจะเลือกขยายใบที่ทำให้ฟังก์ชันสูญเสียลดลงได้มากที่สุด แทนที่จะขยายทุกใบในระดับเดียวกันอย่างที่ XGBoost ทำ ประกอบกับการใช้ Histogram-based Algorithm ในการกำหนดจุดแบ่งตัวแปร ทำให้ LightGBM ใช้ทั้งเวลาและหน่วยความจำน้อยกว่าอย่างมีนัยสำคัญ จึงเหมาะอย่างยิ่งกับงานที่มีตัวแปรจำนวนมากและต้องการประสิทธิภาพสูงในระดับการใช้งานจริง [7]

Li, Xu และ Liu (2022) ได้พัฒนาต่อยอดโดยผสาน LightGBM เข้ากับเทคนิคการปรับค่าไฮเปอร์พารามิเตอร์แบบ TPE (Tree-structured Parzen Estimator) ผลการศึกษาพบว่าแบบจำลองที่ได้ทำการจำแนกความรุนแรงของอุบัติเหตุได้ดีกว่าทั้ง Random Forest และ XGBoost ในหลายตัวชี้วัด แถมยังชี้ได้ชัดว่าตัวแปรไหนมีผลมาก เช่น สภาพอากาศ ลักษณะถนน และจำนวนรถที่เกี่ยวข้อง ทำให้ LightGBM น่าสนใจทั้งเรื่องความแม่นยำ ความเร็ว และการอ่านผลได้ง่าย [8]

2.5 CatBoost

Prokhorenkova และคณะ (2018) ได้ทำการนำเสนอ CatBoost เป็น Gradient Boosting ที่พัฒนาเพื่อแก้ปัญหา Prediction Shift ซึ่งเป็นความเอนเอียงทางสถิติที่พบในการนำข้อมูลชุดเดียวกันมาใช้ทั้งในการสร้างและประเมินแบบจำลอง โดยนำเสนอนวัตกรรม 2 ประการ ได้แก่ Ordered Boosting ที่ใช้หลักการเรียงลำดับข้อมูลเพื่อหลีกเลี่ยง Target Leakage และ Ordered Target Statistics สำหรับแปลง Categorical Features เป็นตัวเลขโดยไม่เกิดการรั่วไหลของข้อมูล นอกจากนี้ CatBoost ยังใช้ Oblivious Decision Trees เป็น Base Predictor ซึ่งเป็น Decision Tree แบบสมมาตรที่ช่วยลดการ Overfitting และเพิ่มความเร็วในการ Inference เปรียบเทียบผลการทดสอบ XGBoost กับ ผลการทดสอบ LightGBM บน 9 ชุดข้อมูลมาตรฐาน พบว่า CatBoost ให้ประสิทธิภาพสูงกว่าทั้งสองแบบจำลองในทุกชุดข้อมูล โดยเฉพาะชุดข้อมูลที่มี Categorical Features จำนวนที่มาก [9]

Roudnitski (2024) ได้ทำการรวมแบบจำลอง ML 5 ตัว (Random Forest, XGBoost, AdaBoost, LightGBM และ CatBoost) เพื่อคาดการณ์ความรุนแรงของอุบัติเหตุ โดยใช้ข้อมูลจากรัฐ New South Wales ออสเตรเลีย ช่วงปี ค.ศ. 2018–2022 จำนวน 57,240 รายการ ข้อมูลครอบคลุมสภาพถนน รูปแบบการชน ชนิดยานพาหนะ กับสภาพแวดล้อม เนื่องจากกลุ่ม Fatal มีแค่ 2.5% ของทั้งหมด จึงใช้ SMOTE ปรับสมดุลก่อน แล้วรวมผลด้วย Soft Voting ผลประเมินได้ ROC-AUC อยู่ที่ 0.68 ปัจจัยที่มีน้ำหนักมากที่สุดคือประเภทของยานพาหนะหลักกับลักษณะการชนครั้งแรก และยังพบว่าอุบัติเหตุร้ายแรงมักเกิดในวันเสาร์บนถนนชนบทที่จำกัดความเร็ว 100 กม./ชม. [10]

2.6 จุดต่างของการศึกษานี้จากงานวิจัยที่ผ่านมา

แม้ว่างานวิจัยที่ผ่านมาจะแสดงให้เห็นถึงศักยภาพของแบบจำลองตระกูล Tree-based ในการจำแนกความรุนแรงของอุบัติเหตุทางถนน แต่งานส่วนใหญ่เลือกใช้แบบจำลองเดี่ยว หรือใช้ Ensemble ที่รวมแบบจำลองหลายตัวที่มีกลไกการเรียนรู้ใกล้เคียงกัน การศึกษานี้จึงนำเสนอกรอบการเปรียบเทียบระหว่างแบบจำลองเดี่ยวกับ Ensemble ของ 3 แบบจำลอง (Random Forest, LightGBM และ CatBoost) ที่คัดเลือกบนพื้นฐานของความหลากหลายของกลไกการเรียนรู้ (Bagging ผสานกับ

Boosting) เพื่อจำแนกระดับความรุนแรงของอุบัติเหตุ 3 ระดับตามมาตรฐาน KABCO

2.7 เหตุผลในการเลือกใช้แบบจำลอง Random Forest, LightGBM และ CatBoost

การศึกษานี้เลือกใช้แบบจำลอง Random Forest, LightGBM และ CatBoost ในการพัฒนาแบบจำลองจำแนกระดับความรุนแรงของอุบัติเหตุ ด้วยเหตุผลสำคัญ 2 ประการดังนี้

ประการแรก แบบจำลองทั้งสามจัดอยู่ในตระกูล Tree-based Ensemble ที่มีโครงสร้างพื้นฐานเป็นต้นไม้ตัดสินใจ ซึ่งสามารถรองรับข้อมูลเชิงหมวดหมู่และข้อมูลผสมประเภท (Mixed-type Data) ได้อย่างมีประสิทธิภาพ สอดคล้องกับลักษณะของชุดข้อมูล Traffic Accidents ที่ประกอบด้วยตัวแปรเชิงหมวดหมู่จำนวนมาก เช่น สภาพอากาศ ลักษณะถนน และประเภทอุบัติเหตุ

ประการที่สอง แบบจำลองทั้งสามใช้กลไกการเรียนรู้ที่แตกต่างกัน โดย Random Forest อาศัยหลักการ Bagging ที่สร้างต้นไม้ตัดสินใจแบบขนานและรวมผลด้วยการลงคะแนนเสียงข้างมาก ในขณะที่ LightGBM และ CatBoost อาศัยหลักการ Boosting ที่สร้างต้นไม้แบบลำดับและเรียนรู้จากความผิดพลาดของรุ่นก่อนหน้า ความหลากหลายของกลไกการเรียนรู้นี้ส่งผลให้ความผิดพลาดของแต่ละแบบจำลองมีลักษณะที่ไม่สหสัมพันธ์กัน (Uncorrelated Errors) ซึ่งเป็นเงื่อนไขสำคัญที่ทำให้การรวมแบบจำลองด้วยวิธี Ensemble Soft Voting สามารถลดความผิดพลาดโดยรวมและเพิ่มความเสถียรของผลการทำนายได้

2.8 Grid Search Cross-Validation

Grid Search Cross-Validation เป็นเทคนิคการปรับค่าไฮเปอร์พารามิเตอร์ (Hyperparameter Tuning) ที่กำหนดค่าที่เป็นไปได้ของแต่ละพารามิเตอร์ในรูปของกริด (Grid) จากนั้นทดสอบทุกชุดผสมที่เป็นไปได้อย่างครบถ้วน และคัดเลือกชุดพารามิเตอร์ที่ให้ประสิทธิภาพดีที่สุดตามเกณฑ์การประเมินที่กำหนดไว้ [13]

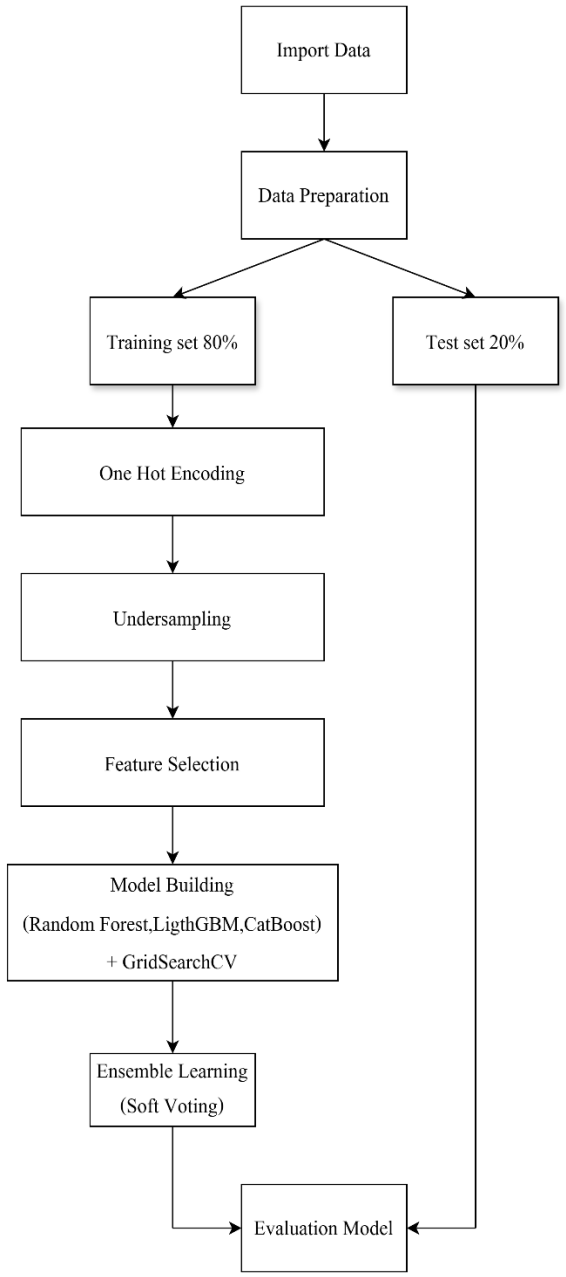
ในการประเมินประสิทธิภาพของแต่ละชุดพารามิเตอร์ ใช้เทคนิค K-Fold Cross-Validation ซึ่งเป็นวิธีการประเมินที่ช่วยลดความเอนเอียงจากการแบ่งข้อมูลเพียงครั้งเดียว โดยมีขั้นตอนการทำงานคือแบ่ง Training set ออกเป็น K ส่วนเท่ากัน จากนั้นดำเนินการฝึกฝนและประเมินแบบจำลองทั้งสิ้น K รอบ ในแต่ละรอบจะใช้ข้อมูลจำนวน K-1 ส่วนสำหรับฝึกฝนแบบจำลอง และใช้ส่วนที่เหลืออีก 1 ส่วนสำหรับประเมินผล ทำให้ข้อมูลทุกตัวอย่างได้รับโอกาสในการเป็นทั้งข้อมูลฝึกฝนและข้อมูลประเมิน ผลการประเมินสุดท้ายของแต่ละชุดพารามิเตอร์คำนวณจากค่าเฉลี่ยของประสิทธิภาพจากทั้ง K รอบ [14]

การศึกษานี้กำหนดค่า K = 5 ซึ่งเป็นค่าที่ได้รับการยอมรับและใช้กันแพร่หลายในงานวิจัยด้านการเรียนรู้ของเครื่อง เนื่องจากให้สมดุลที่เหมาะสมระหว่างความน่าเชื่อถือของผลการประเมินและการใช้ทรัพยากรในการคำนวณ [14] การกำหนดค่า K = 5 หมายความว่า Training set จะถูกแบ่งออกเป็น 5 ส่วน โดยในแต่ละรอบของกระบวนการ Cross-Validation จะใช้ข้อมูล 4 ส่วน (ร้อยละ 80 ของ Training set) สำหรับฝึกฝนแบบจำลอง และใช้อีก 1 ส่วน (ร้อยละ 20 ของ Training set) สำหรับประเมินผล

นอกจากนี้ การศึกษานี้ใช้ Stratified K-Fold Cross-Validation ซึ่งเป็นรูปแบบหนึ่งของ K-Fold ที่รักษาสัดส่วนของแต่ละคลาสในทุก Fold ให้ใกล้เคียงกับสัดส่วนของ Training set เดิม ซึ่งมีความสำคัญอย่างยิ่งสำหรับการศึกษานี้ เนื่องจากข้อมูลที่ใช้มีลักษณะคลาสไม่สมดุล (Class Imbalance) หากใช้ K-Fold รูปแบบทั่วไป อาจเกิดกรณีที่บาง Fold มีตัวอย่างของคลาส KA (ซึ่งเป็นคลาสส่วนน้อย) น้อยมากหรือไม่มีเลย อันจะส่งผลให้การประเมินขาดความน่าเชื่อถือ

3. วิธีการดำเนินงานวิจัย

3.1 ภาพรวมกระบวนการดำเนินงาน (Process overview)



รูปที่ 1 แผนภาพภาพรวมของกระบวนการดำเนินงาน

กรอบของการจำลองนี้ตั้งเป้าสร้างแบบจำลองเพื่อที่สามารถจำแนกได้ว่าเหตุรถชนบนท้องถนนแต่ละครั้งมีความรุนแรงอยู่ในระดับไหน โดยใช้แบบจำลอง Random Forest, LightGBM, CatBoost และ Ensemble ขั้นตอนทำงานทั้งหมดแสดงไว้ในรูปที่ 1 รายละเอียดแต่ละขั้นตอนดังนี้

3.1.1 Import Data

ข้อมูลที่ใช้นั้นได้มาจากชุดข้อมูลอุบัติเหตุทางถนน (Traffic Accidents Dataset) ของ Oktay Ördekçi จากแพลตฟอร์ม Kaggle [2] ซึ่งประกอบด้วยข้อมูล 209,306 แถว และ 18 ตัวแปร ครอบคลุมรายละเอียดสำคัญ เช่น วัน–เวลาที่เกิดเหตุ ประเภทและสภาพพื้นผิวของถนน สภาพอากาศ จำนวนผู้บาดเจ็บ รวมถึง ระดับความรุนแรงของอุบัติเหตุ ซึ่งทำหน้าที่เป็นตัวแปรตาม

สำหรับการประมวลผลเบื้องต้น มีการนำเข้าข้อมูลด้วยภาษา Python และจัดการข้อมูลด้วยไลบรารีหลัก ได้แก่ pandas, NumPy และ scikit-learn เพื่อให้ข้อมูลมีความพร้อมสำหรับการวิเคราะห์เชิงสถิติและการพัฒนาแบบจำลองในขั้นตอนถัดไป

3.1.2 Data Preparation

ขั้นตอนนี้เป็นการทำความสะอาดและเตรียมข้อมูลให้มีพร้อมเพื่อการนำไปวิเคราะห์ โดยมีการดำเนินการรวมระดับความรุนแรงของอุบัติเหตุจากเดิม 5 ระดับ (FATAL, INCAPACITATING INJURY, NONINCAPACITATING INJURY, REPORTED NOT EVIDENT, และ NO INDICATION OF INJURY) ให้เหลือ 3 ระดับ โดยอ้างอิงแนวคิดการจำแนกระดับของความรุนแรงตามมาตรฐาน KABCO โดยใช้แนวทางมาตรฐานในการจัดระดับของความรุนแรงการบาดเจ็บจากอุบัติเหตุทางถนน [11] การรวมคลาสกำหนดเป็น 3 กลุ่มดังนี้

1. Severe (KA): รวมกรณีเสียชีวิตและบาดเจ็บรุนแรง ได้แก่ FATAL และ INCAPACITATING INJURY
2. Minor (BC): รวมกรณีบาดเจ็บเล็กน้อยหรือมีการรายงานอาการบาดเจ็บแต่ไม่ปรากฏชัด ได้แก่ NONINCAPACITATING INJURY และ REPORTED, NOT EVIDENT
3. No injury (O): กรณีไม่ปรากฏข้อบ่งชี้ของการบาดเจ็บ ได้แก่ NO INDICATION OF INJURY

3.1.3 Data Splitting

หลังเตรียมข้อมูลเรียบร้อยแล้ว ผู้วิจัยแบ่งข้อมูลเป็น 2 ก้อน คือ Training set 80% สำหรับฝึกฝนแบบจำลอง

กับ Test set 20% สำหรับวัดผล โดยใช้ฟังก์ชัน train_test_split() จาก scikit-learn พร้อมเปิดใช้ Stratified Sampling เพื่อให้สัดส่วนของแต่ละคลาสในทั้งสองก้อนใกล้เคียงกัน

3.1.4 Encoding

ในขั้นตอนนี้จะแปลงข้อมูลเชิงหมวดหมู่ให้อยู่ในรูปตัวเลข โดยใช้ One-Hot Encoding กับตัวแปรอิสระทั้งหมด ยกตัวอย่างเช่น ตัวแปร "Weather Condition" ที่มี 5 ประเภท จะถูกแตกออกเป็น 5 คอลัมน์ใหม่ แต่ละคอลัมน์มีค่า 0 หรือ 1 ระบุว่าแถวนั้นอยู่ในประเภทไหน

3.1.5 Undersampling

ข้อมูลในงานนี้มีปัญหาคลาสไม่สมดุลค่อนข้างสูง คลาส No Injury มีตัวอย่างมากกว่าคลาส Severe อยู่หลายเท่า ถ้าเอาข้อมูลแบบนี้ไปฝึกฝนแบบจำลองตรง ๆ มีแนวโน้มทำนายเฉพาะคลาสที่ข้อมูลมาก แล้วละเลยคลาสที่มีน้อย ผู้วิจัยจึงเลือกใช้ Undersampling เพื่อจัดการปัญหานี้

วิธีทำคือสุ่มลดข้อมูลจากคลาสที่มากออก จนเหลือเท่ากับคลาสที่น้อยที่สุด ขั้นตอนนี้ทำเฉพาะกับ Training set เท่านั้น ไม่ดำเนินการกับ Test set เพราะถ้าไปปรับ Test set ด้วย ผลการวัดประสิทธิภาพจะไม่ตรงกับสถานการณ์จริง

3.1.6 Feature Selection

มีการกำจัดตัวแปรที่ซ้ำซ้อนออกและทำให้แบบจำลองได้มีประสิทธิภาพที่มากขึ้นที่เกิดจากการเรียนรู้ ผู้วิจัยกรองตัวแปรอิสระด้วยไคสแควร์ โดยมีการเก็บเพียงเฉพาะตัวแปรที่มีค่า p-value ต่ำกว่า 0.05 ไว้ใช้สร้างแบบจำลองสำหรับทำงานในขั้นถัดไป

3.1.7 Model Building

แบบจำลองสำหรับการจำแนกทั้งหมด 3 ตัว ได้แก่

1. Random Forest (RF)
2. LightGBM
3. CatBoost

3.1.8 Hyperparameter Tuning

เพื่อปรับแต่งสมรรถนะของแบบจำลอง ได้ดำเนินการเพื่อค้นหาค่าการตั้งค่าด้วย GridSearchCV โดยเลือกใช้กระบวนการ Cross-Validation แบบ Stratified K-Fold จำนวน K = 5 สำหรับแต่ละแบบจำลอง การประเมินในลำดับขั้นตอนจูนนี้ใช้ตัวชี้วัด F1-macro ซึ่งให้น้ำหนักเท่ากันกับทุกคลาส ช่วยสะท้อนถึงประสิทธิภาพของแบบจำลองในสถานการณ์ที่ข้อมูลมีความไม่สมดุลระหว่างคลาส

3.1.9 Ensemble Learning

นำแบบจำลองทั้ง 3 ได้แก่ Random Forest, LightGBM และ CatBoost มารวมกันด้วยวิธี Soft Voting Ensemble โดย Zhou (2012) อธิบายว่าการรวมแบบจำลองหลายตัวที่มีจุดเด่นต่างกันเพื่อช่วยลดค่าของความผิดพลาดและเพิ่มความเสถียรของผลการทำนายได้ดีกว่าเมื่อเทียบกับการใช้แบบจำลองเดี่ยว

Soft Voting ต่างจาก Hard Voting ตรงที่ไม่ได้เพียงแค่นับว่าแบบจำลองส่วนใหญ่ทายว่าเป็นคลาสไหน แต่จะนำค่าความน่าจะเป็นจากแต่ละแบบจำลองมาเฉลี่ย แล้วเลือกคลาสที่ได้ค่าเฉลี่ยที่สูงที่สุด วิธีนี้จึงใช้ข้อมูลเชิงความมั่นใจของแบบจำลองได้ครบถ้วนกว่า [12]

เหตุผลที่เลือก Soft Voting มี 3 ข้อ ข้อแรก ใช้ค่าความน่าจะเป็นแทนการนับคะแนนเสียง จึงสะท้อนระดับความมั่นใจได้ดีกว่า ข้อที่สอง Kuncheva (2014) ระบุว่า Soft Voting ได้เปรียบ Hard Voting ในปัญหาที่ข้อมูลไม่สมดุล ซึ่งตรงกับข้อมูลอุบัติเหตุในงานนี้ที่คลาส KA มีจำนวนน้อยกว่าคลาสอื่นมาก [15] ข้อที่สาม Niculescu-Mizil และ Caruana (2005) พบว่า Soft Voting ทำงานได้ดีเมื่อแบบจำลองที่นำมารวมประมาณค่าความน่าจะเป็นได้แม่นยำ ซึ่ง Random Forest, LightGBM และ CatBoost ต่างมีความสามารถนี้ [16]

วิธี Soft Voting คำนวณผลการทำนายสุดท้ายตามสมการที่ Zhou (2012) นำเสนอดังนี้

$$\hat{y} = argmax_c \sum_{i=1}^{3} w_i \cdot P_i(c) \quad (1)$$

เมื่อ $P_i(c)$ คือค่าความน่าจะเป็นไปได้ที่แบบจำลอง i ทำนายว่าตัวอย่างอยู่ในระดับของความรุนแรง c และ $w_i = \frac{1}{3}$ สำหรับทุกแบบจำลอง เนื่องจากกำหนด

น้ำหนักเท่ากันเพื่อให้แต่ละแบบจำลองมีอิทธิพลต่อผลลัพธ์อย่างเท่าเทียม ทั้งนี้แบบจำลองทั้ง 3 ถูกฝึกฝนด้วย Training set และประเมินผลบน Test set ชุดเดียวกัน โดยใช้ค่า F1-macro เป็นเกณฑ์หลักในการเลือกเปรียบเทียบประสิทธิภาพระหว่างแบบจำลองเดี่ยวและ Ensemble

3.1.10 Evaluation Model

เมื่อปรับแต่งค่าพารามิเตอร์จนได้แบบจำลองที่ความเหมาะสมแล้ว ก็นำไปทดสอบกับ Test set เพื่อวัดผลด้วยตัวชี้วัดต่อไปนี้

- Accuracy: ความแม่นยำถูกต้องรวมของแบบจำลอง
- Precision, Recall และ F1-Score (Macro Average): วัดผลความสามารถในการจำแนกแต่ละคลาส
- Confusion Matrix: แสดงรายละเอียดว่าถูกจำแนกถูกต้องและผิดพลาดจำนวนเท่าใด

ผลจากทั้ง 4 แบบจำลอง (RF, LightGBM, CatBoost และ Ensemble) จะถูกเปรียบเทียบกันเพื่อหาว่าแบบจำลองใดเหมาะสมกับงานจำแนกความรุนแรงของอุบัติเหตุมากที่สุด

4. ผลการดำเนินงาน

4.1 Data Preparation

ข้อมูลที่ใช้ในการดำเนินการนี้ได้มาจากชุดข้อมูล “Traffic Accidents” จาก Kaggle จำนวน 209,306 แถว 18 ตัวแปร หลังจากทำความสะอาดข้อมูล ลบค่าที่ไม่ทราบ (“UNKNOWN”) เหลือข้อมูลที่ใช้ในการวิเคราะห์ทั้งสิ้น 171,519 แถว 17 ตัวแปร และได้ดำเนินการรวมระดับความรุนแรงของอุบัติเหตุจากเดิม 5 ระดับ ให้เหลือ 3 ระดับ อ้างอิงตามแนวคิดการจัดระดับของความรุนแรงแบบ KABCO ดังนี้

1. Severe (KA) ได้แก่ FATAL และ INCAPACITATING INJURY จำนวน 5,941 แถว
2. Minor (BC) ได้แก่ NONINCAPACITATING INJURY และ REPORTED NOT EVIDENT จำนวน 40,049 แถว
3. No Injury (O) ได้แก่ NO INDICATION OF INJURY จำนวน 125,529 แถว

4.2 Data Splitting

การแบ่งชุดข้อมูลดำเนินการโดยใช้ฟังก์ชัน train_test_split() ของไลบรารี Scikit-learn โดยจัดสรรแบ่งส่วนของข้อมูลออกเป็น 2 ส่วน ดังต่อไปนี้ Training set ร้อยละ 80 จำนวน 137,215 แถว และ Test set ร้อยละ 20 จำนวน 34,304 แถว ทั้งนี้ใช้การสุ่มข้อมูลรูปแบบ Stratified Sampling เพื่อคงสัดส่วนของแต่ละคลาสในตัวแปรตามให้ใกล้เคียงกันทั้งในชุดฝึกฝนและชุดทดสอบ ดังแสดงในตารางที่ 1

ตารางที่ 1 จำนวนข้อมูลในแต่ละคลาสของ Training set และ Test set

Class	Training set (rows)	Test set (rows)
Severe (K+A)	4,753	1,188
Minor (B+C)	32,039	8,010
No Injury (O)	100,423	25,106
Total	137,215	34,304

4.3 Encoding

ดำเนินการเข้ารหัสข้อมูลโดยใช้เทคนิค One-Hot Encoding สำหรับตัวแปรอิสระเชิงพรรณนา (Categorical Features) ทั้งหมด เพื่อดัดแปลงข้อมูลฝึกสอนให้อยู่ในรูปแบบตัวเลขที่แบบจำลองสามารถประมวลผลได้ โดยตัวแปรแต่ละตัวจะถูกขยายออกเป็นตัวแปรย่อยตามจำนวนหมวดหมู่ที่มี และกำหนดค่า 0 หรือ 1 แทนการมีอยู่ของแต่ละหมวดหมู่ หลังจากผ่านกระบวนการ One-Hot Encoding แล้ว ชุดข้อมูลมีจำนวนตัวแปรทั้งสิ้น 140 ตัวแปร ซึ่งพร้อมสำหรับการนำเข้าสู่กระบวนการสร้างแบบจำลองในขั้นตอนถัดไป

4.4 Undersampling

เนื่องจากชุดข้อมูลมีความไม่สมดุลของคลาส (Class Imbalance) การศึกษานี้จึงใช้เทคนิค Undersampling เพื่อปรับสมดุลข้อมูลใน Training set ก่อนนำไปฝึกฝนแบบจำลอง โดยดำเนินการสุ่มลดจำนวนตัวอย่างของคลาสที่มีจำนวนมากให้เท่ากับคลาสที่มีจำนวน

น้อยที่สุด ผลของการทำ Undersampling แสดงในตารางที่ 2

ตารางที่ 2 จำนวนข้อมูลในแต่ละคลาสก่อนและหลังการทำ Undersampling

Class	Before Undersampling (rows)	After Undersampling (rows)
Severe (K+A)	4,753	4,753
Minor (B+C)	32,039	4,753
No Injury (O)	100,423	4,753
Total	137,215	14,259

จากตารางที่ 2 จะเห็นว่าหลังจากดำเนินการทำวิธี Undersampling แล้ว Training set มีจำนวนตัวอย่างในแต่ละคลาสเท่ากันที่ 4,753 แถวต่อคลาส รวมทั้งสิ้น 14,259 แถว ทั้งนี้กระบวนการ Undersampling ดำเนินการเฉพาะบน Training set เท่านั้น โดย Test set ยังคงสัดส่วนข้อมูลตามธรรมชาติเพื่อให้การประเมินผลสะท้อนสถานการณ์จริง

4.5 Feature Selection

หลังกรองด้วยไคสแควร์ที่ระดับ p-value ต่ำกว่า 0.05 มีตัวแปรผ่านเกณฑ์ 51 ตัว จากจำนวนเริ่มต้น 140 ตัว ตัวแปรทั้ง 51 ตัวนี้ถูกนำไปใช้กับทั้ง 3 แบบ

เมื่อนำแบบจำลองที่ได้ผ่านการฝึกสอนมาวิเคราะห์ความสำคัญของตัวแปร พบว่าวิธีการเรียนรู้ของโมเดลแต่ละอันให้ลำดับความสำคัญที่แตกต่างกัน ดังแสดงในตารางที่ 3

ตารางที่ 3 ตัวแปรที่มีความสำคัญสูงสุด 3 อันดับแรกของแต่ละแบบจำลอง

Class	Rank	Feature
RF	1	cat__crash_type_INJURY AND / OR TOW DUE TO CRASH
	2	cat__crash_type_NO INJURY / DRIVE AWAY
	3	cat__first_crash_type_PEDESTRIAN
LightGBM	1	num__crash_hour
	2	num__num_units
	3	cat__crash_type_INJURY AND / OR TOW DUE TO CRASH
CatBoost	1	cat__crash_type_INJURY AND / OR TOW DUE TO CRASH
	2	cat__crash_type_NO INJURY / DRIVE AWAY
	3	cat__first_crash_type_PEDESTRIAN

จากตารางที่ 3 จะเห็นว่า Random Forest และ CatBoost ให้ลำดับความสำคัญของตัวแปรที่สอดคล้องกัน โดยทั้งสองแบบจำลองจัดให้ประเภทของอุบัติเหตุที่มีการบาดเจ็บหรือต้องลากรถ (cat__crash_type INJURY AND/OR TOW DUE TO CRASH) เป็นตัวแปรที่สำคัญที่สุด ในขณะที่ LightGBM ให้ความสำคัญกับตัวแปรเชิงตัวเลข ได้แก่ ชั่วโมงที่เกิดเหตุ (num__crash_hour) และจำนวนยานพาหนะที่เกี่ยวข้อง (num__num_units) เป็นลำดับแรก แต่ละวิธีการเชิงคำนวณมีลักษณะของรูปแบบการเรียนรู้ที่แตกต่างออกไป

4.6 Model Building & Tuning

ทำการฝึกสอนและปรับค่าไฮเปอร์พารามิเตอร์เพื่อให้ได้ค่าที่เหมาะกับแบบจำลองด้วย Grid Search Cross-Validation (5-fold) โดยใช้ F1-Macro เป็นเกณฑ์ ซึ่งได้ค่าที่เหมาะสมที่สุด (Best Parameters) ดังตารางที่ 4

ตารางที่ 4 ผลการปรับค่าความเหมาะสมของแบบจำลองด้วยวิธี Grid Search Cross Validation

Model	Best Parameters	F1-Macro
RF	{'max_depth':10, 'min_samples_leaf':2, 'min_samples_split':5, 'n_estimators':300}	0.5393
LightGBM	{'colsample_bytree':1.0, 'learning_rate':0.05, 'max_depth':5, 'min_child_samples':10, 'n_estimators':200, 'num_leaves':15, 'subsample':0.6}	0.5343
CatBoost	{'depth':6,	0.5321

	'iterations':1000, 'l2_leaf_reg':7, 'learning_rate':0.03}	

4.7 Ensemble Learning

การศึกษานี้นำแบบจำลองทั้ง 3 ได้แก่ Random Forest, LightGBM และ CatBoost มารวมกันด้วยวิธี Soft Voting Ensemble โดยคำนวณค่าเฉลี่ยของความน่าจะเป็นจากแต่ละแบบจำลองด้วยน้ำหนักเท่ากัน ($w = \frac{1}{3}$) แล้วเลือกคลาสที่มีค่าความน่าจะเป็นรวมสูงสุดเป็นผลการทำนายสุดท้าย

4.8 Evaluation Model

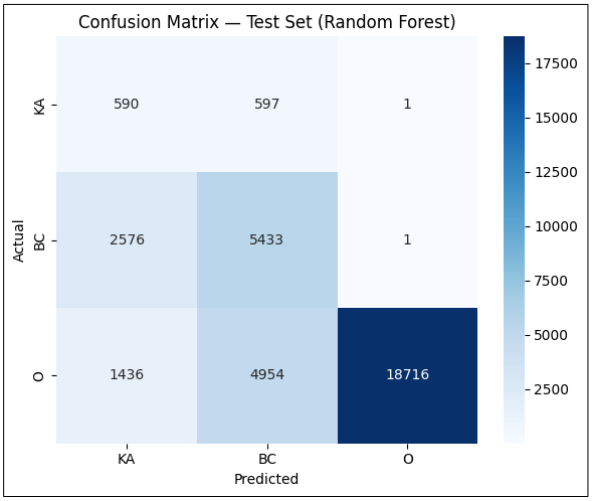
4.8.1 Random Forest

ผลของการประเมินผลประสิทธิภาพสำหรับแบบจำลอง Random Forest บน Test set แสดงในตารางที่ 5

ตารางที่ 5 ค่า accuracy, precision, recall และ f1-score ของ Random Forest

Class	precision	recall	f1-score
KA (Severe)	0.1282	0.4966	0.2038
BC (Minor)	0.4946	0.6783	0.5721
O (No Injury)	0.9999	0.7455	0.8541
Accuracy			0.7212
Macro avg	0.5409	0.6401	0.5433
Weighted avg	0.8517	0.7212	0.7658

จากตารางที่ 5 จะพบเห็นว่าแบบจำลอง Random Forest มีค่า Accuracy อยู่ที่ 0.7212 และค่า F1-macro อยู่ที่ 0.5433 เมื่อพิจารณารายคลาส พบได้ว่าแบบจำลองมีประสิทธิภาพที่สูงในการจำแนกคลาส O (No Injury) โดยได้ค่า F1-Score เท่ากับ 0.8541 แต่มีผลประสิทธิภาพที่ต่ำในการจำแนกคลาส KA (Severe) ซึ่งได้ค่า F1-Score เพียง 0.2038 สะท้อนให้เห็นว่าแบบจำลองยังคงมีความลำเอียงต่อคลาสที่มีจำนวนมากกว่า



รูปที่ 2 confusion matrix ของ Random Forest

จาก Confusion Matrix ในรูปที่ 2 พบว่าคลาส KA มีการจำแนกผิดพลาดสูง โดยถูกทำนายเป็นคลาส BC จำนวน 597 ตัวอย่าง จากทั้งหมด 1,188 ตัวอย่าง ในขณะที่คลาส O ถูกจำแนกถูกต้องมากที่สุดจำนวน 18,716 ตัวอย่าง

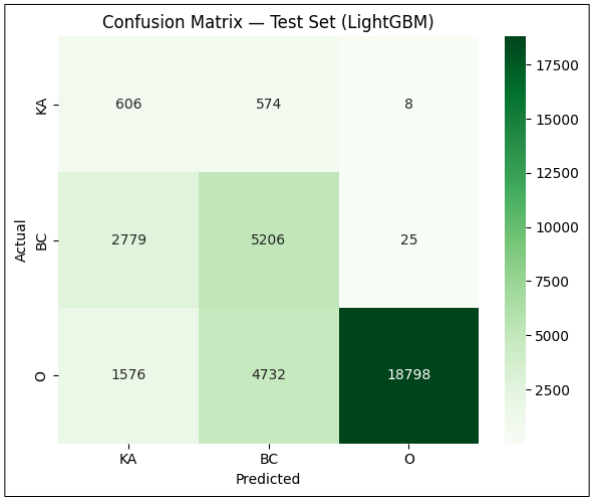
4.8.2 LightGBM

ผลของการประเมินผลประสิทธิภาพสำหรับแบบจำลอง LightGBM บน Test set แสดงในตารางที่ 6

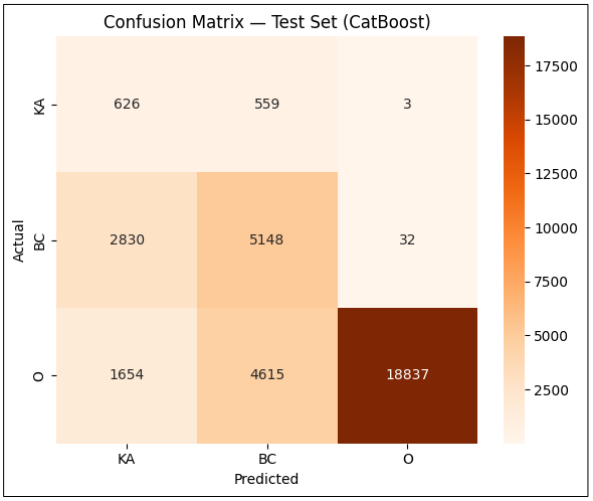
ตารางที่ 6 ค่า accuracy, precision, recall และ f1-score ของ LightGBM

Class	precision	recall	f1-score
KA (Severe)	0.1222	0.5101	0.1971
BC (Minor)	0.4952	0.6499	0.5621
O (No Injury)	0.9982	0.7487	0.8557
Accuracy			0.7174
Macro avg	0.5385	0.6363	0.5383
Weighted avg	0.8505	0.7174	0.7643

จากตารางที่ 6 จะพบเห็นว่าแบบจำลอง LightGBM มีค่า Accuracy อยู่ที่ 0.7174 และค่า F1-macro อยู่ที่ 0.5383 เมื่อพิจารณารายคลาส พบว่ามีรูปแบบที่คล้ายคลึงกับ Random Forest จะกล่าวว่าแบบจำลองมีประสิทธิภาพที่สูงในการจำแนกคลาส O (No Injury) ได้ค่า F1-Score เท่ากับ 0.8557 แต่มีประสิทธิภาพที่ต่ำในการจำแนกคลาส KA (Severe) ซึ่งได้ค่า F1-Score เพียง 0.1971



รูปที่ 3 confusion matrix ของ LightGBM



รูปที่ 4 confusion matrix ของ CatBoost

จาก Confusion Matrix ในรูปที่ 3 พบว่าคลาส KA มีการจำแนกผิดพลาดสูง โดยถูกทำนายเป็นคลาส BC จำนวน 574 ตัวอย่าง และถูกทำนายเป็นคลาส O จำนวน 8 ตัวอย่าง จากทั้งหมด 1,188 ตัวอย่าง ในขณะที่คลาส O ถูกจำแนกถูกต้องมากที่สุดจำนวน 18,798 ตัวอย่าง

4.8.3 CatBoost

ผลของการประเมินผลประสิทธิภาพสำหรับแบบจำลอง CatBoost บน Test set แสดงในตารางที่ 7

ตารางที่ 7 ค่า accuracy, precision, recall และ f1-score ของ CatBoost

Class	precision	recall	f1-score
KA (Severe)	0.1225	0.5269	0.1988
BC (Minor)	0.4987	0.6427	0.5616
O (No Injury)	0.9981	0.7503	0.8567
Accuracy			0.7174
Macro avg	0.5398	0.6400	0.5390
Weighted avg	0.8512	0.7174	0.7650

จากตารางที่ 7 จะพบเห็นว่าแบบจำลอง CatBoost มีค่า Accuracy อยู่ที่ 0.7174 และค่า F1-macro อยู่ที่ 0.5390 เมื่อพิจารณารายคลาส พบว่าคลาส O (No Injury) ได้ค่า F1-Score สูงสุดเท่ากับ 0.8567 ในขณะเดียวกันคลาส KA (Severe) ยังคงมีค่า F1-Score ต่ำที่สุดเท่ากับ 0.1988 สะท้อนให้เห็นว่าแม้จะใช้เทคนิค Undersampling แล้ว การจำแนกคลาสส่วนน้อยยังคงเป็นความท้าทายของแบบจำลอง

จาก Confusion Matrix ในรูปที่ 4 พบว่าคลาส KA มีการจำแนกผิดพลาดโดยถูกทำนายเป็นคลาส BC จำนวน 559 ตัวอย่าง และถูกทำนายเป็นคลาส O จำนวน 3 ตัวอย่าง จากทั้งหมด 1,188 ตัวอย่าง ในขณะที่คลาส O ถูกจำแนกถูกต้องมากที่สุดจำนวน 18,837 ตัวอย่าง ซึ่งเป็นค่าสูงสุดในบรรดาแบบจำลองเดี่ยวทั้งหมด

4.8.4 Ensemble

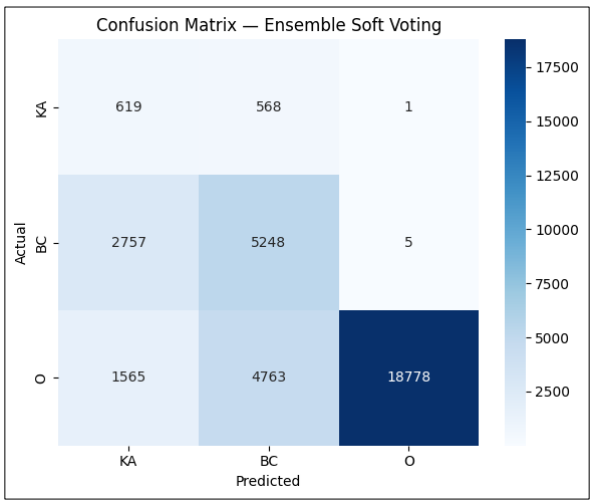
ผลของการประเมินผลประสิทธิภาพสำหรับแบบจำลอง Ensemble Soft Voting บน Test set แสดงในตารางที่ 8

ตารางที่ 8 ค่า accuracy, precision, recall และ f1-score ของ Ensemble Soft Voting

Class	precision	recall	f1-score
KA (Severe)	0.1253	0.5210	0.2020
BC (Minor)	0.4961	0.6552	0.5646
O (No Injury)	0.9997	0.7479	0.8557
Accuracy			0.7184
Macro avg	0.5403	0.6414	0.5408
Weighted avg	0.8518	0.7184	0.7651

จากตารางที่ 8 จะพบเห็นว่าแบบจำลอง Ensemble Soft Voting มีค่า Accuracy อยู่ที่ 0.7184 และค่า F1-macro ของ Ensemble Soft Voting อยู่ที่ 0.5408 ใกล้เคียงกันกับแบบจำลองเดี่ยวที่ดีที่สุดคือ Random

Forest ที่ได้ 0.5433 แสดงให้เห็นว่าการรวมแบบจำลองช่วยรักษาระดับประสิทธิภาพโดยรวมได้อย่างสม่ำเสมอ



รูปที่ 5 confusion matrix ของ Ensemble Soft Voting

จาก Confusion Matrix ในรูปที่ 5 พบว่าคลาส KA ถูกจำแนกถูกต้องจำนวน 619 ตัวอย่าง ซึ่งสูงกว่า Random Forest แต่ต่ำกว่า CatBoost เล็กน้อย ในขณะที่คลาส O ถูกจำแนกถูกต้องจำนวน 18,778 ตัวอย่าง ผลลัพธ์นี้สอดคล้องกับลักษณะของข้อมูลที่มีความไม่สมดุลของคลาสสูง ซึ่งเป็นข้อจำกัดร่วมที่ทุกแบบจำลองในการศึกษานี้เผชิญ

5. สรุปผลและแนวทางในอนาคต

5.1 สรุปผลการวิจัย

การศึกษาครั้งนี้มุ่งวิเคราะห์ปัจจัยที่เกี่ยวข้องกับระดับความรุนแรงของอุบัติเหตุทางถนน และพัฒนาแบบจำลอง Machine Learning สำหรับจำแนกระดับของความรุนแรงแบ่งออกได้เป็น 3 ระดับ ได้แก่ Severe (KA), Minor (BC) และ No Injury (O) ใช้วิธีการเชิงคำนวณ Random Forest, LightGBM และ CatBoost รวมถึง Soft Voting Ensemble บนชุดข้อมูล Traffic Accidents จาก Kaggle จำนวน 171,519 แถว

ผลการประเมินประสิทธิภาพสำหรับแบบจำลองทั้งหมดบน Test set สรุปได้ดังตารางที่ 9

ตารางที่ 9 สรุปเปรียบเทียบประสิทธิภาพของแบบจำลองทั้งหมด

Model	Accuracy	Macro Precision	Macro Recall	F1-Macro
RF	0.7212	0.5409	0.6401	0.5433
LightGBM	0.7174	0.5385	0.6363	0.5383
CatBoost	0.7174	0.5398	0.6400	0.5390
Ensemble Soft Voting	0.7184	0.5403	0.6414	0.5408

จากตารางที่ 9 พบว่า Random Forest ให้ค่า F1-Macro สูงสุดที่ 0.5433 รองลงมาคือ Ensemble Soft Voting ที่ 0.5408 ส่วน CatBoost และ LightGBM ได้ค่า F1-Macro ที่ 0.5390 และ 0.5383 ตามลำดับ

เมื่อพิจารณาประสิทธิภาพในการจำแนกคลาส KA (Severe) ซึ่งเป็นคลาสที่มีความสำคัญสูงมากที่สุดในเชิงความปลอดภัย พบว่า CatBoost ให้ค่า Recall สูงสุดที่ 0.5269 สามารถตรวจจับอุบัติเหตุรุนแรงได้ถูกต้อง 626 ตัวอย่าง รองลงมาคือ Ensemble Soft Voting ที่ Recall 0.5210 จำนวน 619 ตัวอย่าง LightGBM ที่ Recall 0.5101 จำนวน 606 ตัวอย่าง และ Random Forest ที่ Recall ต่ำสุดที่ 0.4966 จำนวน 590 ตัวอย่าง อย่างไรก็ตามทุกแบบจำลองแสดงรูปแบบร่วมกัน คือมีประสิทธิภาพที่สูงในการจำแนกคลาส O (No Injury) แต่มีประสิทธิภาพที่ต่ำในการจำแนกคลาส KA (Severe) สะท้อนให้เห็นว่าความไม่สมดุลของคลาสในข้อมูลยังคงเป็นความท้าทายหลักของการศึกษานี้ แม้จะใช้เทคนิค Undersampling แล้วก็ตาม

ในด้านตัวแปรสำคัญ ประเภทอุบัติเหตุ (crash type) และลักษณะการชนครั้งแรก (first crash type) เป็นปัจจัยที่มีน้ำหนักมากที่สุดใน RF และ CatBoost ขณะที่ LightGBM ให้ความสำคัญกับชั่วโมงเกิดเหตุและจำนวนยานพาหนะเป็นหลัก ความแตกต่างนี้เกิดจากวิธีการเรียนรู้ที่ต่างกันของแต่ละอัลกอริทึม

5.2 แนวทางในอนาคต

เพื่อการยกระดับประสิทธิภาพของแบบจำลองในทำการศึกษาต่อไปในอนาคต มีข้อเสนอแนะสำคัญ 2 ประการดังนี้

ประการแรก ควรประยุกต์ใช้เทคนิคจัดการคลาสไม่สมดุลทางเลือกอื่น เช่น SMOTE หรือ ADASYN ซึ่งทำงานโดยสร้างตัวอย่างใหม่ขึ้นมาในคลาสที่มีน้อย แทนที่จะตัดข้อมูลจากคลาสที่มีเยอะทิ้ง วิธีนี้อาจช่วยลดการสูญเสียข้อมูลและทำให้แบบจำลองจำแนกคลาส KA ได้ดีขึ้น

ประการที่สอง ควรเพิ่มตัวแปรที่เกี่ยวข้องกับพฤติกรรมและสภาพของผู้ขับขี่เข้าสู่แบบจำลอง เช่น ระดับความเร็วของยานพาหนะ การใช้โทรศัพท์ในขณะขับขี่ หรือจะเป็นสภาพร่างกายของผู้ขับขี่ ณ เวลาเกิดเหตุ เนื่องจากตัวแปรเหล่านี้มีความสัมพันธ์โดยตรงกับระดับความรุนแรงของอุบัติเหตุ และอาจช่วยให้แบบจำลองนั้นมีความสามารถในการแยกแยะคลาสที่มีความรุนแรงสูงได้ดียิ่งขึ้นไป

เอกสารอ้างอิง

[1] World Health Organization. (2018*). Global status report on road safety 2018*. สืบค้นเมื่อ 16 สิงหาคม 2568, จาก https://www.who.int/publications/i/item/9789241565684

[2] Ördekçi, O. (2025). *Traffic Accidents* [Data set, CSV]. สืบค้น 7 กรกฎาคม 2568, จาก https://www.kaggle.com/datasets/oktayrdeki/traffic-accidents

[3] Agresti, A. (2018). *Statistical Methods for the Social Sciences* (5th ed.). Pearson Education.

[4] Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (2nd ed.). O'Reilly Media.

[5] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32. doi:10.1023/A:1010933404324

[6] Wang, X., Su, Y., Zheng, Z., and Xu, L. (2024). Prediction and interpretive of motor vehicle traffic crashes severity based on random forest optimized by meta-heuristic algorithm. *Heliyon*, 10(11),e35595. doi:10.1016/j.heliyon.2024.e35595

[7] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., and Liu, T. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Proceedings of the 31st International Conference on Neural Information Processing Systems (NeurIPS 2017)*, pp.3149–3157. https://dl.acm.org/doi/10.5555/3294996.3295074

[8] Li, K., Xu, H., & Liu, X. (2022). Analysis and visualization of accidents severity based on LightGBM-TPE. *Chaos, Solitons & Fractals*, 157, 111987. doi:10.1016/j.chaos.2022.111987

[9] Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, 31, 6638–6648. สืบค้นจาก https://proceedings.neurips.cc/paper/2018/hash/14491b756b3a51daac41c24863285549-Abstract.html

[10] Roudnitski, A. (2024). Evaluating road crash severity prediction with balanced ensemble models. *Findings*.doi:10.32866/001c.116820

[11] Federal Highway Administration. (n.d.). *KABCO injury classification scale and definitions* [PDF].

U.S. Department of Transportation. สืบค้นจาก https://highways.dot.gov/media/20141

[12] Zhou, Z.-H. (2012). *Ensemble methods: Foundations and algorithms*. CRC Press.

[13] Bergstra, J., & Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13, 281–305. สืบค้นจาก https://jmlr.org/papers/v13/bergstra12a.html

[14] Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*, 1137–1145. สืบค้นจาก https://www.ijcai.org/Proceedings/95-2/Papers/016.pdf

[15] Kuncheva, L. I. (2014). *Combining Pattern Classifiers: Methods and Algorithms* (2nd ed.). Wiley. doi:10.1002/9781118914564

[16] Niculescu-Mizil, A., & Caruana, R. (2005). Predicting good probabilities with supervised learning. *Proceedings of the 22nd International Conference on Machine Learning (ICML)*, 625–632. doi:10.1145/1102351.1102430